

TRƯỜNG CÔNG NGHỆ THÔNG TIN VÀ TRUYỀN THÔNG – ĐẠI HỌC BÁCH KHOA HÀ NỘI

HỌC PHẦN: QUẢN TRỊ DỮ LIỆU VÀ TRỰC QUAN HÓA (IT5425)

BÁO CÁO KỸ THUẬT TIẾN ĐỘ PHÂN HỆ 2

Quản trị Chất lượng Dữ liệu Lâm sàng, Kiểm soát K-Anonymity & L-Diversity
trên Clinical Data Lakehouse

Thành viên 2: Clinical Data Governance & Privacy Lead

Nhóm Nghiên cứu Y sinh (Biomedicine Research Group) – Lớp IT5425

Tháng 10 Năm 2026

Tóm tắt nội dung

Tài liệu này tổng kết kết quả triển khai kỹ thuật của **Phân hệ 2 (TV 2 – Clinical Data Governance & Privacy Lead)** trong dự án Bài tập lớn học phần *Quản trị Dữ liệu và Trực quan hóa (IT5425)*. Phân hệ tiếp nhận bảng `clinical_events` do Pipeline 01 bàn giao, thiết lập hợp đồng dữ liệu gồm **61 quy tắc Great Expectations**, kiểm tra đầy đủ lược đồ, tính duy nhất, tính đầy đủ, miền giá trị và các ràng buộc sinh lý học trên **9.240 hồ sơ**. Sau vòng phản hồi quản trị và làm sạch dữ liệu thượng nguồn, lần đánh giá ngày 07/10/2026 ghi nhận **61/61 quy tắc đạt** (100%), không còn expectation thất bại. Song song, mô hình riêng tư toán học bằng **pyCANON** cho thấy dữ liệu gốc chỉ đạt $k = 1, l = 1$, trong khi khung dữ liệu phát hành sau khi loại định danh trực tiếp và tổng quát hóa tuổi đạt $k = 21, l = 2$, vượt ngưỡng chính sách $k \geq 5, l \geq 2$. Do cả Quality Gate và Privacy Gate đều đạt, **Governance Gate tổng thể PASS**. Việc vượt ngưỡng k-anonymity/l-diversity là đánh giá rủi ro theo mô hình thuộc tính đã khai báo, không phải chứng nhận pháp lý HIPAA.

Mục lục

1	Tổng Quan Mục Tiêu & Vị Trí Của Phân Hệ 2	2
2	Đặc Tả Kỹ Thuật Các Thành Phần Đã Xây Dựng	2
2.1	Cấu hình chính sách quản trị (<code>configs/governance.yaml</code>)	2
2.2	Bộ nạp dữ liệu và hợp đồng chất lượng (<code>governance/gx.py</code>)	2
2.3	Đánh giá riêng tư toán học (<code>governance/anon.py</code>)	3
2.4	Điều phối Pipeline 02 (<code>pipelines/02_gov.py</code>)	3
3	Kết Quả Thực Nghiệm Trên 9.240 Hồ Sơ	4
3.1	Kết quả Great Expectations	4
3.2	Kết quả k-anonymity và l-diversity	4
3.3	Quyết định governance tổng thể	5

4 Kiểm Thử, Tái Lập & Bằng Chứng	5
4.1 Bộ kiểm thử tự động	5
4.2 Các artifact bằng chứng	5
5 Giới Hạn, Rủi Ro & Kế Hoạch Khắc Phục	6
6 Bàn Giao Cho Các Phân Hệ Hạ Nguồn	6
7 Kết Luận	6

1 Tổng Quan Mục Tiêu & Vị Trí Của Phân Hệ 2

Phân hệ 2 tạo lớp kiểm soát nằm giữa hạ tầng dữ liệu của TV 1 và các tác vụ phân tích, mô hình hóa, trực quan hóa ở hạ nguồn. Mục tiêu không phải che giấu dữ liệu lỗi, mà là biến chất lượng và rủi ro tái định danh thành các tiêu chí có thể đo lường, tái chạy và kiểm toán.

- **Hợp đồng dữ liệu lâm sàng:** xác nhận quy mô bảng, sự hiện diện của cột, khóa định danh, mức độ đầy đủ, miền sinh lý và bộ thuật ngữ được quản trị.
- **Cổng chất lượng (Quality Gate):** chỉ đánh dấu đạt khi toàn bộ expectation bắt buộc thành công; mọi sai lệch được lưu cùng số lượng và tỷ lệ bản ghi bất thường.
- **Mô hình đe dọa riêng tư:** phân biệt định danh trực tiếp, quasi-identifier và thuộc tính nhạy cảm; đo rủi ro trước và sau tổng quát hóa.
- **Bằng chứng kiểm toán:** sinh báo cáo máy đọc được, dấu vân tay SHA-256 của dataset và tài liệu tổng hợp phục vụ bàn giao.
- **Bảo vệ các phân hệ hạ nguồn:** ngăn việc coi dữ liệu đầu vào là sạch tuyệt đối khi các ngoại lệ sinh lý vẫn còn tồn tại.

Luồng xử lý chính của Pipeline 02 được mô tả như sau:

Delta Lake/CSV $\longrightarrow$ 61 Quality Expectations $\longrightarrow$ Quality Evidence
 $\longrightarrow$ Generalization $\longrightarrow$ (k, l) Privacy Evidence.

2 Đặc Tả Kỹ Thuật Các Thành Phần Đã Xây Dựng

2.1 Cấu hình chính sách quản trị (configs/governance.yaml)

Toàn bộ ngưỡng được tách khỏi mã nguồn để có thể kiểm toán và thay đổi có kiểm soát. Cấu hình hiện tại quy định tập dữ liệu phải có đúng 9.240 dòng, tỷ lệ đầy đủ tối thiểu 95% đối với các trường không thuộc nhóm bắt buộc tuyệt đối, và hai ngưỡng riêng tư $k \geq 5$, $l \geq 2$.

Nguồn vào mặc định là `data/lakehouse/delta/clinical_events`. Khi Delta Lake không tồn tại, chế độ `auto` chuyển sang `data/mart/preview_cohort.csv`. Cơ chế này giúp cùng một hợp đồng có thể áp dụng cho cả môi trường đầy đủ và bản preview bàn giao.

2.2 Bộ nạp dữ liệu và hợp đồng chất lượng (governance/gx.py)

Bộ kiểm tra sử dụng Great Expectations 1.23.2. Tổng số **61 expectation** được cấu thành như Bảng 1.

Các miền sinh lý đang áp dụng gồm: tuổi 18–100; huyết áp tâm thu $(0, 300]$; huyết áp tâm trương $(0, 200]$; BMI 10–80; nhịp tim 20–250; glucose 20–600; cholesterol toàn phần 50–700; số điều thuốc mỗi ngày 0–100.

Nhóm kiểm tra	Số lượng	Ý nghĩa quản trị
Số dòng của bảng	1	Dataset phải có đúng 9.240 hồ sơ.
Sự tồn tại của cột	20	Toàn bộ trường trong hợp đồng phải hiện diện.
Tính duy nhất của <code>person_id</code>	1	Không trùng khóa đại diện bệnh nhân.
Đầy đủ tuyệt đối	6	Sáu trường trọng yếu không được null.
Đầy đủ tối thiểu 95%	14	Kiểm soát missingness ở các trường còn lại.
Miền giá trị sinh lý	8	Tuổi, huyết áp, BMI, nhịp tim, glucose, cholesterol và thuốc lá.
Quan hệ tâm thu–tâm trương	1	Yêu cầu <code>sys_bp ≥ dia_bp</code> .
Miền nhị phân	7	Các cờ lâm sàng chỉ nhận 0 hoặc 1.
Bộ thuật ngữ quản trị	3	Nguồn dữ liệu, phân tầng huyết áp và ICD-10 đúng danh mục.
Tổng cộng	61	Hợp đồng dữ liệu y sinh có thể tái chạy.

Bảng 1: Cấu trúc bộ quy tắc Great Expectations.

2.3 Đánh giá riêng tư toán học (governance/anon.py)

Mô hình đe dọa chia thuộc tính thành ba nhóm:

- **Định danh trực tiếp:** `person_id`; trường này bị loại khỏi view phát hành.
- **Quasi-identifier gốc:** `age`, `is_male`, `center_source`.
- **Thuộc tính nhạy cảm:** `ten_year_chd`.

Với tập quasi-identifier Q , k-anonymity được xác định bởi kích thước nhỏ nhất của một lớp tương đương:

$$k(D, Q) = \min_{q \in \pi_Q(D)} |q|.$$

L-diversity được xác định theo số giá trị phân biệt nhỏ nhất của thuộc tính nhạy cảm S trong các lớp tương đương:

$$l(D, Q, S) = \min_{q \in \pi_Q(D)} |\{s : (q, s) \in D\}|.$$

Biện pháp giảm thiểu đang áp dụng là loại `person_id`, bỏ tuổi chính xác và ánh xạ sang bốn dải <40, 40-49, 50-59, 60+. View phát hành dùng $Q' = \{\text{age_band}, \text{is_male}, \text{center_source}\}$.

2.4 Điều phối Pipeline 02 (pipelines/02_gov.py)

Pipeline hỗ trợ ba tham số vận hành:

- **-config:** chọn tệp chính sách quản trị.
- **-source auto|delta|csv:** chọn nguồn dữ liệu hoặc cho phép fallback.
- **-strict:** trả exit code 1 nếu quality gate hoặc privacy gate không đạt, phù hợp tích hợp CI/CD.

Không bật **-strict**, pipeline vẫn hoàn thành và lưu bằng chứng khi phát hiện lỗi. Thiết kế này cho phép quá trình audit ghi nhận finding thay vì dừng trước khi sinh báo cáo.

3 Kết Quả Thực Nghiệm Trên 9.240 Hồ Sơ

3.1 Kết quả Great Expectations

Lần đánh giá mới nhất được lưu trong artifact ngày 07/10/2026, sử dụng nguồn Delta Lake `clinical_events` gồm 9.240 dòng. Kết quả tổng hợp được trình bày trong Bảng 2.

Chỉ tiêu	Kết quả
Tổng số expectation được đánh giá	61
Expectation thành công	61
Expectation không thành công	0
Tỷ lệ thành công	100,00%
Quyết định Quality Gate	PASS

Bảng 2: Tổng hợp kết quả hợp đồng chất lượng dữ liệu.

Quality Gate đạt toàn bộ hợp đồng

Toàn bộ 61 expectation đều thành công. Không còn vi phạm miền huyết áp, BMI hoặc quan hệ `sys_bp >= dia_bp` trong dataset sau làm sạch.

Finding ở vòng đầu	Trước	Sau	Biện pháp làm sạch thượng nguồn
<code>sys_bp >= dia_bp</code>	99	0	Chuẩn hóa thang đo và hoán đổi hai cột khi cặp giá trị nằm trong dải hợp lý.
Miền <code>sys_bp</code> (0, 300]	4	0	Sửa lỗi thang đo; ngoại lệ cực đoan được thay thế bằng giá trị quy ước 125 mmHg.
Miền <code>dia_bp</code> (0, 200]	67	0	Loại số 0 nhập thừa; ngoại lệ cực đoan được thay thế bằng 80 mmHg.
Miền BMI [10, 80]	1	0	Chuẩn hóa chiều cao nhập sai trước khi tính lại BMI.

Bảng 3: Đóng vòng phản hồi giữa Governance và làm sạch dữ liệu thượng nguồn.

Kết quả thể hiện một chu trình quản trị khép kín: Pipeline 02 phát hiện sai lệch nhưng không tự ý sửa dữ liệu; các finding được phản hồi về Pipeline 01 để chuẩn hóa chiều cao, sửa thang đo huyết áp, xử lý cột nhập ngược và thay thế ngoại lệ cực đoan. Sau khi tái tạo Delta Lake, Pipeline 02 chạy ở chế độ `-strict` và đạt 61/61 quy tắc.

3.2 Kết quả k-anonymity và l-diversity

View	Quasi-identifier	k	$l_{\min}$	Kết quả
Baseline, tuổi chính xác	<code>age, is_male, center_source</code>	1	1	FAIL
View phát hành, tuổi tổng quát	<code>age_band, is_male, center_source</code>	21	2	PASS

Bảng 4: So sánh rủi ro riêng tư trước và sau tổng quát hóa.

Privacy Gate đạt trên view phát hành

Sau khi loại định danh trực tiếp và tổng quát hóa tuổi, lớp tương đương nhỏ nhất có 21 hồ sơ và mỗi lớp có tối thiểu 2 giá trị của `ten_year_chd`. Kết quả vượt các ngưỡng cấu hình $k \geq 5$ và $l \geq 2$.

Dataset được gắn dấu vân tay SHA-256:

eae5e595b0b0b08af84ceb53e090fa996a8fab4ff80135c86d91ae242be56243

Dấu vân tay cho phép liên kết kết quả đánh giá với đúng phiên bản dữ liệu nhưng không thay thế chữ ký số hay cơ chế kiểm soát truy cập.

3.3 Quyết định governance tổng thể

Governance Gate tổng thể: PASS

Quality Gate đạt 61/61 expectation và Privacy Gate của view phát hành đạt $k = 21$, $l = 2$. Theo phép hội logic của Pipeline 02, trạng thái tổng thể là **PASS**; dataset đủ điều kiện kỹ thuật để bàn giao theo chính sách quản trị đã khai báo.

4 Kiểm Thử, Tái Lập & Bằng Chứng

4.1 Bộ kiểm thử tự động

Tập `tests/test_governance.py` định nghĩa bốn trường hợp kiểm thử:

- tạo thành công Data Docs khi mẫu dữ liệu tuân thủ hợp đồng;
- phát hiện ngoại lệ sinh lý khi huyết áp tâm thu vượt miền cho phép;
- xác nhận tổng quát hóa tuổi giúp đạt đồng thời k-anonymity và l-diversity;
- xác nhận l-diversity thất bại khi thuộc tính nhạy cảm đồng nhất.

Các lệnh tái lập chính:

```
# Chạy pipeline và sinh day du bang chung
python pipelines/02_gov.py

# Bat governance gate cho CI/CD
python pipelines/02_gov.py --strict

# Chạy bo kiem thu cua Phan he 2
python -m pytest tests/test_governance.py -q
```

4.2 Các artifact bằng chứng

Kết quả gốc của lần chạy được lưu trong:

- `reports/data_quality_summary.json`: xác nhận 61/61 expectation thành công và không còn finding.
- `reports/privacy_certificate.json`: ngưỡng, quasi-identifier, kết quả k/l và SHA-256.
- `reports/data_docs/`: website kỹ thuật do Great Expectations sinh tự động, dùng để truy vết chi tiết trong quá trình phát triển.

Báo cáo PDF hiện tại là tài liệu bàn giao gọn, đồng bộ định dạng với Phân hệ 1. Data Docs HTML và chứng chỉ privacy là sản phẩm nghiệm thu trực quan; các JSON đi kèm cung cấp bằng chứng máy đọc được và khả năng tái lập.

5 Giới Hạn, Rủi Ro & Kế Hoạch Khắc Phục

1. **Giả định trong quy tắc làm sạch:** các phép đổi thang đo, hoán đổi cột và thay thế ngoại lệ bằng 125/80 mmHg cần được duy trì cùng provenance; PASS của hợp đồng không chứng minh giá trị thay thế là quan sát gốc.
2. **K-anonymity không chống mọi tấn công:** k lớn không loại bỏ tấn công dựa trên kiến thức nền; l -diversity cũng chưa đo độ lệch phân phối như t -closeness.
3. **Mô hình thuộc tính có phạm vi hữu hạn:** kết quả hiện tại chỉ đúng với ba quasi-identifier và một thuộc tính nhạy cảm đã khai báo. Bổ sung biến địa lý, thời gian hoặc chẩn đoán có thể làm giảm k và l .
4. **Không phải chứng nhận HIPAA:** kết quả là bằng chứng kỹ thuật hỗ trợ đánh giá rủi ro. Tuân thủ pháp lý còn phụ thuộc kiểm soát truy cập, mục đích sử dụng, hợp đồng, quy trình vận hành và chuyên gia đủ thẩm quyền.
5. **Quản lý artifact:** Data Docs chứa nhiều tài nguyên tĩnh nhưng là sản phẩm nghiệm thu cần mở trực tiếp bằng trình duyệt. Mỗi lần tái tạo dataset phải sinh lại Data Docs, JSON và certificate tương ứng.

Kế hoạch duy trì là: (1) lưu vết số bản ghi bị biến đổi theo từng quy tắc làm sạch; (2) theo dõi drift của phân phối huyết áp và BMI; (3) chạy Pipeline 02 với **-strict** trong CI/CD; (4) cập nhật fingerprint và toàn bộ artifact sau mỗi phiên bản dữ liệu; (5) đánh giá lại tập quasi-identifier khi bổ sung thuộc tính mới.

6 Bàn Giao Cho Các Phân Hệ Hạ Nguồn

- **TV 3 – EDA:** sử dụng dataset đã qua Quality Gate, đồng thời phân biệt giá trị gốc và giá trị đã làm sạch khi diễn giải phân phối huyết áp/BMI.
- **TV 4/TV 5 – Mô hình hóa:** huấn luyện trên dataset đã đạt governance gate; ghi rõ cohort, quy tắc làm sạch và fingerprint để bảo đảm khả năng tái lập.
- **TV 6 – Dashboard:** chỉ hiển thị dữ liệu release view, không phát hành `person_id` hoặc tuổi chính xác nếu chưa có kiểm soát truy cập phù hợp.
- **Tích hợp CI/CD:** dùng `python pipelines/02_gov.py -strict` để ngăn bản phát hành mới khi quality/privacy gate thất bại.

7 Kết Luận

Phân hệ 2 đã xây dựng được một lớp quản trị có thể cấu hình và tái lập trên Clinical Data Lakehouse: 61 quy tắc chất lượng, phản hồi finding về tầng tích hợp, đo k-anonymity/l-diversity trước và sau biến đổi, cùng dấu vân tay dataset. Vòng đánh giá mới nhất đạt 61/61 expectation; view phát hành đạt $k = 21$, $l = 2$; do đó governance gate tổng thể **PASS**. Kết quả chứng minh chu trình phát hiện–khắc phục–tái kiểm định đã hoạt động, đồng thời vẫn yêu cầu lưu provenance cho các giá trị làm sạch và không diễn giải privacy gate như chứng nhận pháp lý HIPAA.