TRƯỜNG CÔNG NGHỆ THÔNG TIN VÀ TRUYỀN THÔNG – ĐẠI HỌC BÁCH KHOA HÀ NỘI

HỌC PHẦN: QUẢN TRỊ DỮ LIỆU VÀ TRỰC QUAN HÓA (IT5425)

BÁO CÁO KỸ THUẬT TIẾN ĐỘ PHÂN HỆ 3

Phân Tích Khám Phá Dữ Liệu Y Sinh (EDA), Kiểm Định Giả Thuyết & Trực Quan Hóa Tỷ Số Chênh (Odds Ratios)

Thành viên 3: Trưởng nhóm Phân tích / EDA & Biostatistics Lead

Nhóm Nghiên cứu Y sinh (Biomedicine Research Group) – Lớp IT5425

Tháng 9 Năm 2026

Tóm tắt nội dung

Tài liệu này tổng kết toàn bộ kết quả triển khai kỹ thuật của **Phân hệ 3 (TV 3 – EDA Lead)** trong dự án Bài tập lớn học phần *Quản trị Dữ liệu và Trực quan hóa (IT5425)*. Phân hệ 3 chịu trách nhiệm tiếp nhận dữ liệu đã được làm sạch từ kho LanceDB (thực hiện bởi Phân hệ 1), tiến hành quy trình Phân tích Khám phá (EDA) và kiểm định giả thuyết thống kê chuyên sâu trên tập mẫu **8,828** hồ sơ bệnh nhân đủ điều kiện. Hệ thống tự động hóa toàn bộ việc xây dựng Bảng đặc điểm lâm sàng (Table 1), áp dụng thuật toán quyết định kiểm định phi tham số (*Mann-Whitney U*, *Chi-square*), và đánh giá mức độ rủi ro mạch vành 10 năm qua mô hình hồi quy Logistic (*Odds Ratios*). Điểm nhấn kỹ thuật của phân hệ là việc chuẩn hóa Z-score các biến liên tục để đưa hệ số rủi ro về cùng thang đo, kết hợp với kỹ thuật trực quan hóa Split-Violin và Forest Plot chuẩn học thuật, giúp minh bạch hóa các yếu tố nguy cơ.

Mục lục

1 Tổng Quan Mục Tiêu & Vị Trí Cốt Lõi Của Phân Hệ 3 **2**

2 Đặc Tả Kỹ Thuật Các Tệp Tin Mã Nguồn Đã Xây Dựng **2**

2.1 Thư viện Kiểm định Thống kê & Biểu đồ (`src/biomed_lake/biostats/test.py`) . 2

2.2 Thư viện Mô hình Logistic & Tỷ Số Chênh (`src/biomed_lake/biostats/odds.py`) 2

2.3 Luồng Thực Thi Toàn Trình (`pipelines/03_eda.py`) 3

3 Kết Quả Phân Tích Thực Nghiệm **3**

3.1 Kết Quả Chạy Pipeline 03 3

3.2 Phân Tích Đơn Biến (Univariate Analysis) 3

3.3 Phân Tích Đa Biến (Forest Plot & Odds Ratio) 4

4 Biện Luận (Discussion) **4**

1 Tổng Quan Mục Tiêu & Vị Trí Cốt Lõi Của Phân Hệ 3

Trong hệ sinh thái luồng dữ liệu của dự án, Phân hệ 3 đóng vai trò "người giải mã"các tín hiệu lâm sàng trước khi đưa vào huấn luyện mô hình học máy:

- **Cung cấp Insight Lâm Sàng:** Đánh giá sự khác biệt phân phối của các chỉ số sinh hóa (tuổi, huyết áp, đường huyết, BMI, cholesterol) giữa nhóm có và không có biến cố tim mạch.
- **Cung cấp Báo cáo Học thuật (Table 1):** Tự động tổng hợp và tính toán báo cáo đặc điểm bệnh nhân ban đầu, tự động chuyển đổi sang các đại lượng thống kê phù hợp như Median [IQR] cho dữ liệu không chuẩn.
- **Sàng Lọc Đặc Trưng (Feature Selection) cho TV 4 & TV 5:** Bảng phân tích Tỷ số chênh (Odds Ratios) là căn cứ định lượng Toán học vững chắc nhất để các thành viên xây dựng mô hình Học Máy (TV 4 & 5) quyết định giữ hay bỏ các biến số trong thuật toán phân lớp.

2 Đặc Tả Kỹ Thuật Các Tệp Tin Mã Nguồn Đã Xây Dựng

Phân hệ 3 đã xây dựng và chuẩn hóa 3 cấu phần mã nguồn phục vụ tính toán thống kê:

2.1 Thư viện Kiểm định Thống kê & Biểu đồ (`src/biomed_lake/biostats/test.py`)

Module chịu trách nhiệm phân tích thống kê mô tả và suy diễn (Univariate Analysis):

- `generate_table_one`**:** Tích hợp thư viện `tableone`, hỗ trợ tham số `nonnormal_cols` để xuất báo cáo dưới dạng Trung vị [Khoảng tứ phân vị] thay vì Mean (SD) đối với dữ liệu bị lệch phân phối. Xuất tự động định dạng CSV và HTML.
- `run_hypothesis_test`**:** Thuật toán kiểm định động thông minh: Tự động chạy *Shapiro-Wilk / Normaltest* để xét phân phối. Do dữ liệu sinh hóa thực tế vi phạm giả định chuẩn, hệ thống tự động rẽ nhánh sử dụng **Mann-Whitney U test** cho biến liên tục và **Chi-square test** cho biến phân loại.
- `plot_biochemical_distributions`**:** Vẽ trực quan hóa bằng kỹ thuật Split-Violin plot lồng ghép Boxplot để biểu diễn mật độ xác suất và các mốc tứ phân vị đối sánh trực tiếp 2 nhóm bệnh lý.

2.2 Thư viện Mô hình Logistic & Tỷ Số Chênh (`src/biomed_lake/biostats/odds.py`)

Module đánh giá rủi ro đa biến (Multivariate Analysis):

- `calculate_or_ci`**:**
  - Khắc phục nhược điểm thang đo gốc bằng cách áp dụng **StandardScaler (Z-score)** cho các biến liên tục (`age, BMI, glucose, tot_chol`). Điều này giúp Tỷ số chênh (OR) phản ánh mức tăng rủi ro tương ứng với 1 độ lệch chuẩn (σ), mang lại góc nhìn tương quan công bằng với các biến phân loại.
  - Xây dựng mô hình `sm.Logit` với hằng số (intercept), trích xuất khoảng tin cậy 95% (95% CI) và p-value.
- `plot_forest`**:** Thuật toán vẽ Forest Plot tự động gán nhãn nhận diện thống kê: Nếu khoảng tin cậy 95% vắt ngang qua mốc đường cơ sở **1.0** (tương đương $p \geq 0.05$), thanh sai số sẽ được tô màu xám mờ để báo hiệu biến số không đạt ý nghĩa thống kê; ngược lại sẽ giữ màu đỏ sẫm.

2.3 Luồng Thực Thi Toàn Trình (pipelines/03_eda.py)

Kịch bản Pipeline kết nối kho lưu trữ LanceDB (từ TV 1), trích xuất Polars DataFrame siêu tốc, cấu hình danh sách các biến phân loại/liên tục, loại bỏ dữ liệu khuyết thiếu (missing values) và kích hoạt song song chuỗi phân tích.

3 Kết Quả Phân Tích Thực Nghiệm

3.1 Kết Quả Chạy Pipeline 03

Hệ thống xử lý **8,828** bệnh nhân đủ điều kiện và in ra báo cáo thống kê:

```
================================================================================
[*] PIPELINE 03: BIOMEDICAL EDA & HYPOTHESIS TESTING
================================================================================
[*] Dang lay du lieu tu LanceDB
[*] Kich thuoc mau du dieu kien phan tich: 8828 benh nhan

--- Giai doan 1: Xay dung Table 1 ---
[+] Dang xay dung Table 1

--- Giai doan 2: Kiem dinh gia thuyet va ve phan phoi ---
[+] Dang kiem dinh gia thuyet
[Ket qua kiem dinh gia thuyet]
         Bien             Kiem dinh        P-value
          age Mann-Whitney U test 2.618994e-159
       sys_bp Mann-Whitney U test 3.320882e-154
       dia_bp Mann-Whitney U test 1.304637e-106
     tot_chol Mann-Whitney U test  3.512924e-05
          BMI Mann-Whitney U test  2.655625e-83
      glucose Mann-Whitney U test 1.109548e-148
      is_male          Chi-square  8.196966e-01
current_smoker          Chi-square  6.420470e-50
     bp_stage          Chi-square 1.814963e-206
     diabetes          Chi-square  1.742776e-27
      bp_meds          Chi-square  6.457047e-01
[+] Dang ve bieu do Split-Violin va Box cho cac chi so sinh hoa

--- Giai doan 3: Tinh toan ti so chenh lech OR va ve bieu do ---
[+] Dang tinh toan Odds Ratio
[Bang OR]
                               CI_lower  CI_upper        OR       p_value
age                            1.554437  1.734007  1.641769  1.065646e-70
tot_chol                       0.780185  0.870939  0.824314  5.886833e-12
BMI                            1.199175  1.327871  1.261883  3.748574e-19
glucose                        1.549288  1.859195  1.697183  5.815642e-30
is_male                        1.092255  1.348847  1.213789  3.190727e-04
current_smoker                 0.617207  0.804815  0.704796  2.378338e-07
diabetes                       0.283383  0.569040  0.401567  2.895679e-07
bp_meds                        0.317220  0.775254  0.495909  2.093361e-03
bp_stage_HYPERTENSIVE_CRISIS   2.655679  5.484808  3.816529  4.528944e-13
bp_stage_NORMAL                0.602265  1.019927  0.783751  6.981020e-02
bp_stage_STAGE_1_HYPERTENSION  0.998858  1.591501  1.260827  5.113440e-02
bp_stage_STAGE_2_HYPERTENSION  2.961045  4.729030  3.742041  2.218684e-28
[+] Dang ve bieu do Forest
[OK] PIPELINE 3 HOAN TAT
```

3.2 Phân Tích Đơn Biến (Univariate Analysis)

Thông qua phép thử Mann-Whitney U và Chi-square, hầu hết các biến số lâm sàng đều cho thấy sự phân tách rủi ro cực kỳ mạnh mẽ giữa nhóm bệnh và nhóm khỏe mạnh. Tuổi tác, huyết áp tâm

thu/tâm trương, BMI và nồng độ đường huyết đều có p-value chạm ngưỡng ~ 0.

3.3 Phân Tích Đa Biến (Forest Plot & Odds Ratio)

Kết quả hồi quy đa biến mang lại những nhận định sâu sắc về trọng số rủi ro:

- **Yếu tố quyết định rủi ro cao nhất:** Bệnh nhân rơi vào Cơn Tăng huyết áp cấp cứu (`HYPERTENSIVE_CRISIS`) và Tăng huyết áp Giai đoạn 2 (`STAGE_2_HYPERTENSION`) đối mặt với nguy cơ biến cố mạch vành tăng vọt, với OR lần lượt là **3.82** và **3.74** lần so với nhóm quy chiếu.
- **Tác động của Sinh hóa & Tuổi tác (Z-score):** Nhờ kỹ thuật chuẩn hóa, ta thấy rõ khi đường huyết (`glucose`) tăng thêm 1 độ lệch chuẩn, rủi ro tăng 69.7% (OR = 1.69). Tương tự, độ tuổi tăng thêm 1σ đẩy rủi ro lên 64.1% (OR = 1.64).

4 Biện Luận (Discussion)

Các kết quả từ Pipeline 03 đặt ra 2 điểm biện luận y khoa và thống kê quan trọng, cần lưu ý cho nhóm lập mô hình Học máy:

1. **Khử Nhiễu (Confounding) của Y tế Can Thiệp:** Mô hình ghi nhận kết quả Nghịch lý lâm sàng khi biến tiểu đường (`diabetes`) có OR = 0.40 và hút thuốc (`current_smoker`) có OR = 0.70. Thay vì kết luận tiểu đường có tác dụng "bảo vệ"tim mạch, hiện tượng này được lý giải bằng yếu tố nhiễu kiểm soát y tế: Những bệnh nhân có bệnh lý nền nặng thường được đưa vào lộ trình quản lý nghiêm ngặt, sử dụng thuốc can thiệp mạnh (statin, chống đông máu), từ đó vô tình làm giảm xác suất xảy ra biến cố trong tập mẫu quan sát so với người bình thường không đi khám.
2. **Phai Mờ Ý Nghĩa Thống Kê Trong Mô Hình Đa Biến:** Trên biểu đồ Forest Plot, vạch CI của `STAGE_1_HYPERTENSION` (Tăng huyết áp Giai đoạn 1) đã chạm mốc 0.998 (nhỉnh hơn 1.0), tương ứng $p = 0.051$. Do đó, biến này được biểu thị bằng thanh màu xám (không đạt mức ý nghĩa $p < 0.05$). Dù ở mức đơn biến nó có sự khác biệt rõ, nhưng khi xét chung với tuổi tác và mức đường huyết cao trong hồi quy Logistic, mức độ rủi ro riêng biệt của Giai đoạn 1 đã bị các yếu tố khác lấn át và giải thích thay.